

# 基于高密度磁触觉阵列的灵巧手感知：多时空深度学习架构与序列长度的对比研究

秦晨 (Qin Chen)

School of Computer Science, The University of Sydney

Sydney, Australia

[qinchen.steven@outlook.com](mailto:qinchen.steven@outlook.com)

## 摘要 (Abstract)

在机器人多指灵巧操作中，触觉感知是实现接触自适应闭环控制的关键。基于高密度磁触觉阵列的柔性传感器凭借其轻量化物理形态与三维力本征解耦能力，为灵巧手多维感知提供了全新范式。然而，如何从高频、高维的原始磁场序列中高效提取时空物理特征，并在算力受限的边缘计算平台上满足严苛的实时控制频率，仍是该系统部署的核心瓶颈。为此，本文基于公开的高保真触觉抓取数据集 (Let's DENSE)，全面对比了四种代表性深层神经网络架构 (1D-CNN, LSTM, Temporal Transformer, ST-GCN)，开展了面向滑移状态检测与细粒度材质识别的多任务感知研究。通过针对时间感受野（序列长度）的平行消融实验，本研究揭示了触觉感知对时序动态特征的底层依赖规律：微观材质纹理的提取必须依托于至少 150 ms (15 帧) 的完整“粘滞-滑移 (Stick-Slip)”摩擦周期；而过长的观测窗口则会因引入静态噪声而损害高频瞬态滑移特征。在跨架构综合评估中，ST-GCN 通过显式建模传感器表面的空间拓扑传导，在材质分类上实现了 99.80% 的极高精度；Transformer 凭借自注意力机制展现出卓越的长序列抗噪能力；但两者的算子特性均引入了超过 1.6 ms 的推理延迟开销。综合考量精度稳定性与硬件闭环控制需求，序列长度为 15 帧的 1D-CNN 架构在维持 0.470 ms 极低延迟的同时，实现了 99.3% 以上的双任务综合感知精度，被确立为本系统的最佳工程部署折中方案。本研究为基于高密度触觉阵列的灵巧感知系统提供了清晰的架构选择与参数配置范式。

**关键词 (Keywords):** 磁触觉阵列 (Magnetic Tactile Array), 灵巧操作 (Dexterous Manipulation), 深度学习 (Deep Learning), 时空图卷积网络 (ST-GCN), 滑移检测 (Slip Detection)

## 1. 引言

机器人灵巧操作（如在手旋转、精细装配及自适应抓取）本质上属于强接触、高动态的物理交互过程。在多指协同操作中，仅依靠视觉感知难以应对末端抓取时的严重视线遮挡问题，更无法直接捕获接触界面的三维力分布、微观滑移状态及局部刚度等动态交互力学参量。因此，赋予多指灵巧手高保真度的触觉感知能力，是实现从开环轨迹执行迈向接触自适应闭环控制的关键瓶颈。

然而，在多关节、结构紧凑的灵巧手上集成高性能触觉皮肤面临着形态兼容性与感知保真度的双重挑战。近年来，以 GelSight<sup>1,2</sup> 及 DIGIT<sup>3</sup> 为代表的视触觉传感器通过微型相机捕获弹性体接触形变，能够提供微米级的高分辨率接触几何信息。然而，其内置的相机和光路反射腔体导致传感器体积较大且呈刚性结构<sup>4</sup>，在多关节、小尺寸的细长灵巧手指尖上的集成仍受到较大物理限制。而传统的压阻、电容式触觉阵列虽易于柔性化，却普遍存在迟滞显著、信号串扰严重以及无法有效解耦三维矢量力（法向力与切向剪切力）的局限，难以满足复杂操作中初始微滑移预警与精细力控的要求。

相比之下，基于弹性体包覆微磁体与微型磁阻/霍尔阵列的高密度磁触觉感知技术，为灵巧手触觉系统提供了一种兼具高紧凑度与多维力解算能力的新范式。该机制具备多项显著优势：首先，其无光路无腔体的轻量化形态具备极薄的剖面厚度，无需庞大的光学结构而能够无缝包覆于多自由度指尖的复杂曲面，不影响关节活动范围；其次，利用磁场矢量的空间动态变化，该方案可本征实现三维矢量力的高灵敏解耦；此外，基于纯电学信号直接读取机制，其采样频率可达千赫兹量级；最后，高密度微型传感单元的阵列化排布有效克服了空间分辨率不足的缺陷。

鉴于此，本文基于高密度磁触觉传感器阵列，开展了面向多指灵巧手的触觉感知架构研究。本研究聚焦于多维触觉信号的时空特征提取瓶颈，提出了从原始磁场序列到接触物理量的高精度解算模型。

## 2. 多时空触觉感知架构设计

为全面评估不同时空特征提取机制在高密度磁触觉感知任务中的性能表现，本文设计并对比了四种代表性的深层神经网络架构：

### 2.1 多任务一维时空卷积网络 (STT-Net)

针对触觉感知信号的高频时序特性，本文设计了基于一维时空卷积（1D-CNN）与多任务学习（Multi-Task Learning）的双头解耦架构 STT-Net。该网络由共享时序特征编码器与解耦多任务分支构成。共享编码器包含三层通道数逐级递增（ $72 \rightarrow 128 \rightarrow 256 \rightarrow 256$ ）的一维卷积层，并串联批归一化（BatchNorm1d）与 ReLU 激活函数。卷积核在时序轴上滑动以提取局部动态接触特征，末端通过一维自适应平均池化层将变长时序统一压缩为 256 维的全局物理表征向量。随后，该特征向量被分别送入两个独立的全连接多层感知机（MLP）分支中，分别输出三维滑移状态预测概率与七维物体分类概率，从而实现多维物理量特征的有效解耦。

### 2.2 时空图卷积网络 (ST-GCN)

考虑到传感器表面由  $6 \times 4$  共 24 个物理三轴磁传感节点构成，相邻节点在受力时具有显著的空间耦合特性（如局部应力由边缘节点向中心传导），本文构建了时空图卷积网络（ST-GCN）。该架构将 24 个传感单元定义为图拓扑顶点，利用物理欧氏距离映射图邻接矩阵的边权重。通过显式建模应力分布的空间拓扑流动，并结合时序卷积网络（TCN），该模型旨在局部接触变形与非规则打滑场景下提取更深层次的几何拓扑特征，进而增强感知的物理约束。

### 2.3 时序自注意力网络 (Temporal Transformer)

为突破传统卷积核固定感受野对长时序信号提取的限制，本文引入了基于自注意力机制（Self-Attention）的时序网络（Temporal Transformer）。该架构将时间窗口内的每一时序帧或传感节点视为独立的 Token 输入 Transformer 编码器。通过直接计算任意时序步之间的全局相关性，该机制能够动态赋予打滑起始点与关键摩擦突变帧更高的注意力权重，进而有效抑制静止状态下的冗余噪声干扰，提升模型对高频瞬态物理特征的捕获能力。

### 2.4 流式循环记忆网络 (LSTM)

面向极端严苛的实时嵌入式部署需求，本文设计了基于门控循环单元的流式循环记忆网络（LSTM）。该架构摒弃了固定的滑动窗口切片模式，采用流式（Streaming）逐帧输入机制，依靠门控结构维护和更新隐状态（Hidden State）。该网络的主要目的是避免推理阶段反复缓存历史数据和重叠卷积运算，仅需单帧输入即可完成感知状态的递推，理论计算开销极小，更适用于边缘侧的低延迟部署。

## 3. 实验设置

### 3.1 任务定义、开源数据集与采样协议

本研究定义了两项核心触觉感知任务：滑移状态检测与物体材质识别。滑移检测包含无滑移稳定接触（NoSlip）、顺时针滑移（slip\_clock）与逆时针滑移（slip\_counterclock）三个状态类别；材质识别则涵盖了具备不同几何曲率与表面摩擦特性的七种日常物体（包括刷子、易拉罐、金属条、品客薯片罐、木条、纸裹木条及胶带裹木条）。

为确保实验数据的多样性与物理泛化性，本研究采用了公开发布的高保真度磁触觉交互数据集（Let's DENSE）<sup>5</sup>。该数据集基于 DENSE 数据采集协议构建，通过对目标物体表面（以传感器最小尺寸的一半为步长  $d$ ）进行二维网格化离散采样，生成了一系列具备不同偏心率的抓取位姿。这种严密的采样策略确保了数据集能够全面覆盖稳定抓取与不同动量（旋转/平移）的微滑移边界状态。为了捕获硬件执行的随机误差与物理扰动，每个抓取位姿均重复执行  $R = 10$  次独立抓取实验。

在数据预处理阶段，为消除传感器弹性体初始预紧应变与环境地磁温漂的静态干扰，所有时序样本均首先执行静态基准校准（Baseline Subtraction）操作：

$$X_{\text{input}} = X_{\text{raw}} - X_{\text{rest}}$$

其中  $X_{\text{rest}}$  为未施加外力交互时的初始静态磁场读数。随后，采用滑动窗口策略切分连续接触序列，时间窗口长度  $W$  依次设置为  $\{5, 10, 15, 20\}$  帧（采样率 100 Hz）。输入张量维度被规范化为  $(C_{\text{in}}, W)$ ，通道数  $C_{\text{in}} = 72$  对应阵列的三轴磁矢量分量。为确保测试集对时间漂移与系统装夹误差具备泛化评估能力，数据集严格按前述的独立实验轮次（Exp）进行跨试验划分（Cross-Trial Partitioning），其中 70% 的轮次用于模型训练，20% 用于验证与超参数调优，剩余 10% 作为未见过的测试集进行最终性能独立盲测。

## 3.2 多任务联合损失函数

鉴于滑移检测与材质识别在底层触觉特征上的高度相关性，所有模型均采用多任务联合监督训练策略。

总损失函数定义为滑移分类损失与物体分类损失的加权和：

$$L_{\text{total}} = \lambda_{\text{slip}} \mathcal{L}_{\text{CE}}(y_{\text{slip}}, \hat{y}_{\text{slip}}) + \lambda_{\text{obj}} \mathcal{L}_{\text{CE}}(y_{\text{obj}}, \hat{y}_{\text{obj}})$$

其中， $\mathcal{L}_{\text{CE}}$  为标准交叉熵损失函数（Cross-Entropy Loss）。基于任务的重要程度与梯度收敛特性，多任务损失权重分别设定为  $\lambda_{\text{slip}} = 1.0$  与  $\lambda_{\text{obj}} = 0.5$ 。

## 3.3 训练实现细节与超参数配置

所有神经网络模型均在统一的 PyTorch 框架及硬件环境下进行训练与评测。训练过程采用带解耦权重衰减的 AdamW 优化器，结合 ReduceLROnPlateau 调度器实现自适应学习率衰减。在训练周期内，系统实时监控验证集损失，并采用最佳权重保存策略（Best Checkpoint）以防止模型过拟合。具体实验超参数与训练环境配置如表 1 所示。

表 1 实验超参数与训练环境配置

| 超参数 / 实验配置           | 设定值                | 说明与机制                             |
|----------------------|--------------------|-----------------------------------|
| 优化器 (Optimizer)      | AdamW              | 带解耦权重衰减的自适应优化器                    |
| 初始学习率 (Initial LR)   | $1 \times 10^{-3}$ | 初始学习步长                            |
| 权重衰减 (Weight Decay)  | $1 \times 10^{-4}$ | $L_2$ 正则化惩罚项                      |
| 批次大小 (Batch Size)    | 512                | 批量训练样本规模                          |
| 迭代轮数 (Epochs)        | 50                 | 最大训练周期数                           |
| 学习率调度 (LR Scheduler) | ReduceLROnPlateau  | 监控指标为验证集损失，衰减因子 0.5，容忍度 3 个 Epoch |
| 最优模型选择策略             | Best Checkpoint    | 根据验证集最小损失保存权重                     |
| 数据加载方式               | In-Memory Cache    | 全量内存驻留加载，多线程并行加速                  |

### 3.4 评估指标与延迟测试协议

模型性能的定量评估涵盖分类精度与系统延迟两个维度。在精度方面，本文统计了测试集上的准确率（Accuracy）、精确率（Precision）、召回率（Recall）与加权 F1 分数（Weighted F1-Score），并引入混淆矩阵（Confusion Matrix）以直观剖析细粒度分类的物理易混淆边界。

在实时推理延迟（Inference Latency）测试中，为模拟机器人真实在线闭环控制中的流式推理状态，输入批次大小（Batch Size）严格固定为 1。测试协议首先执行 10 次 GPU 前向预热以消除内核初始化抖动，随后连续运行 100 次单步前向传播并计算其平均单次耗时（ms），以此作为边缘计算部署可行性的严谨参考基准。

## 4. 实验结果与深度分析

### 4.1 时序感受野对特征提取的影响与架构敏感性

触觉感知在本质上高度依赖时间上下文信息。为探究观测窗口对不同网络架构的影响规律，本研究针对  $W \in \{5, 10, 15, 20\}$  的序列长度进行了平行消融实验。




图 1: 1D-CNN 架构下序列长度对滑移与材质多任务分类精度的影响

实验表明，基于时序窗口滑动的 1D-CNN 与具有记忆门控机制的 LSTM 在面对序列长度变化时呈现出相似的物理特征依赖规律。在滑移检测任务中，过长的时间窗口（如  $W = 20$ ）不可避免地引入了滑移发生前后的静止期数据。这种静态数据稀释了高频瞬态激振特征，导致 1D-CNN 和 LSTM 的滑移检测准确率分别出现不同程度的回落。相反，在材质分类任务中，模型对微观纹理特征的提取必须依托于连续滑动产生的完整“粘滞-滑移（Stick-Slip）”周期，因此  $W = 15$ （即 150 ms）成为这两种架构提取频域签名的最优窗口下限。




图2: Temporal Transformer 架构下序列长度对分类精度的影响

相比之下, Temporal Transformer 展现出了卓越的时序抗噪鲁棒性。在  $W = 20$  时, 其多头自注意力机制 (Multi-head Self-Attention) 通过动态计算注意力权重矩阵, 能够自动聚焦于发生打滑的关键激振帧, 有效屏蔽了长序列带来的冗余噪声, 使得滑移准确率维持在 99.55% 的高位。

## 4.2 空间拓扑建模对微观纹理识别的提升

上述时序网络均将 72 维磁触觉信号在一维空间上展平, 忽略了磁触觉阵列底层相邻物理节点之间的应力传导关系。为了验证空间几何拓扑的影响, 本研究引入了 ST-GCN。






图3: ST-GCN 架构下序列长度对分类精度的影响

实验结果表明，ST-GCN 在物体材质分类任务上展现出了显著的性能优势。在  $W = 10$  的观测窗口下，ST-GCN 的材质分类准确率达到 99.80%，有效降低了前述时序模型在相似材质（如纸张与胶带）边缘上的局部混淆。这一现象从物理机制上证明：物体表面微观纹理在滑动时引发的微弱应力传导，高度遵循传感器物理表面的空间分布。图邻接矩阵显式聚合了相邻节点信息，从而提升了模型对触觉空间几何特征的解析能力。

### 4.3 多架构综合性能评估与闭环实时性权衡

面向机器人高频闭环控制的实际部署需求，本节选取了四种架构在各自最佳时间窗口（Sweet Spot）下的模型进行横向对比评估，核心性能指标详见表 2 与跨架构对比图（图 4, 图 5）。

表 2 多架构最优配置下的综合性能与延迟对比

| 网络架构        | 最优序列长度 ( ) | 滑移检测准确率 (%)  | 材质分类准确率 (%) | 单次推理延迟 (ms)  | 模型特点与优势            |
|-------------|------------|--------------|-------------|--------------|--------------------|
| 1D-CNN      | 15         | 99.32        | 99.51       | <b>0.470</b> | 计算极简，极低延迟，适合严苛实时系统 |
| LSTM        | 15         | 99.52        | 99.57       | 0.660        | 流式推理稳定，隐状态表征能力强    |
| Transformer | 5          | <b>99.52</b> | 99.30       | 1.605        | 极短序列强表征，抗长时序噪声能力优异 |

| 网络架构   | 最优序列长度 (W) | 滑移检测准确率 (%) | 材质分类准确率 (%) | 单次推理延迟 (ms) | 模型特点与优势             |
|--------|------------|-------------|-------------|-------------|---------------------|
| ST-GCN | 10         | 99.28       | 99.80       | 1.753       | 空间物理拓扑建模，微观纹理分类精度极高 |




图 4：四种触觉感知架构在最佳序列长度下的滑移与材质分类准确率对比




图 5：四种触觉感知架构单次前向推理延迟基准测试对比

如表 2 及图 4、图 5 所示，在边缘计算部署中存在明显的底层权衡规律。Transformer 与 ST-GCN 分别在抗噪性和空间特征解析上表现优异，但其底层算子（如  $O(N^2)$  的自注意力计算与爱因斯坦求和矩阵乘法）带来了不可忽视的算力开销，导致推理延迟普遍高于 1.6 ms。相比之下，1D-CNN 凭借 0.47 ms 的超低延迟，成为满足严苛控制环路频率（百赫兹级）且兼顾精度的首选方案。基于实际硬件算力资源与操作控制频率要求，本文最终确立基于 **1D-CNN ( $W = 15$ )** 作为在线闭环防滑控制的默认部署架构。

#### 4.4 最优感知模型的误差模式与物理可解释性分析

为验证模型是否切实学习到接触力学规律而非过拟合环境噪声，本节对最优部署模型（1D-CNN,  $W = 15$ ）的混淆矩阵进行剖析。




图 6: 1D-CNN ( $W=15$ ) 模型滑移检测任务混淆矩阵






图 7: 1D-CNN (W=15) 模型物体材质分类任务混淆矩阵

如图 6 与图 7 所示，在材质分类任务中，模型面临的最大误差源于将 `woodBarPaper`（纸张包裹木条）与 `woodBarTape`（胶带包裹木条）混淆（错判 148 次）。这一局部误差在物理层面具有高度的合理性：纸张与胶带作为附着在同一木质基材上的薄层材料，在滑过磁触觉硅胶表面时所激发的微观接触形变与摩擦振荡模式高度同源。这种发生于物理边界特征上的合理混淆，从侧面印证了本文所提出的深度学习感知体系成功实现并解耦了真实物理世界的三维接触属性。

## 5. 结论

本文针对多指灵巧手触觉感知在轻量化与高动态响应上的严苛需求，构建了基于高密度磁触觉阵列的多时空深度学习感知体系。为突破复杂动态交互中的时空特征提取瓶颈，本文系统性地对比了 1D-CNN、LSTM、Transformer 与 ST-GCN 四种表征学习架构，并深入探究了时序感受野（序列长度）对多维接触力学解算与滑移预警的底层影响机制。


综合实验结果与硬件基准测试表明：时间上下文窗口对触觉物理规律的提取具有决定性作用。在材质分类任务中，模型必须依赖足够长的时间窗口（150 ms）以捕获完整的粘滞-滑移摩擦周期；而在滑移检测中，过长的观测序列反而会因引入静态噪声而降低感知精度。在架构横向对比中，尽管 ST-GCN 凭借显式的空间物理拓扑建模在微观纹理识别上达到了极高的精度（99.80%），Transformer 也在长时序抗噪上展现出卓越能力，但两者的算子特性导致了显著的延迟惩罚（> 1.6 ms）。综合考量边缘计算平台的算力约束与百赫兹级的闭环控制需求，序列长度为 15 帧的 1D-CNN 架构在维持 0.47 ms 极低延迟的同时实现了 99.3% 以上的感知精度，是当前系统部署的最佳折中方案。

本研究为基于高密度触觉阵列的灵巧感知系统提供了清晰的架构选择与参数配置范式。未来的工作将聚焦于将该感知系统集成至真实多指灵巧手硬件平台，进一步开展动态抓取与在手操作（In-hand Manipulation）的闭环力控策略（Sim2Real）验证。

# 附录

## 附录 A：网络架构延迟与精度权衡全景图

下图详细展示了四种网络架构在不同序列长度下的完整推理延迟与精度权衡，展现了各架构最佳时间窗口（Sweet Spot）的演变过程与选取依据。



附图 A1：各触觉感知架构的时间序列窗口消融与延迟权衡帕累托图

# 参考文献

1. M. K. Johnson and E. H. Adelson, "Retrographic sensing for the measurement of surface texture and shape," in *2009 IEEE Conference on Computer Vision and Pattern Recognition*, 2009, pp. 1070-1077. [↗](#)
2. W. Yuan, S. Dong, and E. H. Adelson, "GelSight: High-resolution robot tactile sensors for estimating geometry and force," *Sensors*, vol. 17, no. 12, p. 2762, 2017. [↗](#)
3. M. Lambeta, P. W. Chou, S. Tian, et al., "DIGIT: A novel design for a low-cost compact high-resolution tactile sensor with application to in-hand manipulation," *IEEE Robotics and Automation Letters*, vol. 5, no. 3, pp. 3838-3845, 2020. [↗](#)
4. E. Donlon, S. Dong, M. Quintana, et al., "GelSlim: A high-resolution, compact, robust, and calibrated tactile sensing finger," in *2018 IEEE/RSJ International Conference on Intelligent Robots and Systems (IROS)*, 2018, pp. 1927-1934. [↗](#)
5. R. Zenha, B. Denoun, A. Cavallaro, A. Bernardino, and L. Jamone, "Let's DENSE: A Novel Protocol for Efficiently Collecting Dense and Diverse Data for Tactile Slip Detection in Robotic Grasping" [Dataset]. Zenodo, Oct. 2025. Available: <https://zenodo.org/records/17336134> [↗](#)